

Generado por Scopus AI, miércoles 29 de octubre de 2025

Medición de la desnutrición crónica infantil

Medición y predicción de la desnutrición crónica infantil (retraso en el crecimiento) utilizando las puntuaciones Z de talla para la edad de la OMS y los datos de la DHS: metodologías, determinantes y enfoques de aprendizaje automático.

Referencia rápida

Tabla de hallazgos clave

Dominio	Predictores/Determinantes clave	Perspectivas de medición/modelado	Brechas/Limitaciones
Materno	Estatura, IMC, nivel educativo, estado de micronutrientes, salud mental	La estatura y el nivel educativo maternos son predictores sólidos; el estado de micronutrientes y la salud mental se utilizan poco en los modelos.	Integración limitada de biomarcadores de micronutrientes y factores psicosociales en modelos de aprendizaje automático
Niño	Edad, peso al nacer, intervalo entre partos, episodios de enfermedad, prácticas de alimentación	La edad del niño y el peso al nacer son predictores consistentemente fuertes; las prácticas de alimentación a menudo están subrepresentadas.	Los errores en la declaración de la edad y los errores de medición, especialmente en menores de 24 meses, afectan la fiabilidad de la puntuación HAZ.
Familiar	Riqueza, tamaño, saneamiento, acceso al agua, combustible para cocinar, contaminación del aire en interiores	La riqueza y el saneamiento son claves; las exposiciones ambientales (por ejemplo, la contaminación del aire) se reconocen cada vez más.	Variables ambientales y comunitarias subrepresentadas en la mayoría de los modelos
Comunidad/Contexto	Urbano/rural, infraestructura, altitud, cobertura de saneamiento comunitario	La residencia urbana y la infraestructura mejoran la zona de riesgo de accidentes cerebrovasculares (HAZ); la cobertura de saneamiento comunitario es un factor determinante contextual importante.	Los predictores a nivel comunitario y ambiental rara vez se incluyen en los modelos de aprendizaje automático.
Enfoques de aprendizaje	Bosque aleatorio, XGBoost, métodos de conjunto,	Los métodos de conjunto superan a los	Integración limitada de diseños de encuestas

Dominio	Predictores/Determinantes clave	Perspectivas de medición/modelado	Brechas/Limitaciones
automático	selección de características (Boruta, LASSO, SHAP)	modelos tradicionales; la selección de características mejora la interpretabilidad.	complejas (ponderaciones, estratos, unidades primarias de muestreo); subutilización de datos espaciales/contextuales.
Medición	OMS HAZ, herramientas rápidas de campo (carta mural MEIRU, Tallstick, RNDA, 3-MinNS), dispositivos digitales	La OMS considera el índice HAZ como referencia; las herramientas rápidas están validadas para su uso en campo; el error de medición en niños pequeños es una preocupación.	Es posible que las normas de la OMS sobreestimen el retraso del crecimiento en algunas regiones; problemas de calidad de los datos y de registro erróneo de la edad.

Respuesta directa

Los principales predictores identificados para los modelos de aprendizaje automático que utilizan datos de las Encuestas Demográficas y de Salud (EDS) sobre la desnutrición crónica infantil, medidos mediante el índice HAZ de la OMS, incluyen características maternas (estatura, nivel educativo, estado nutricional, salud mental), características del niño (edad, peso al nacer, enfermedades, prácticas de alimentación) y factores del hogar (riqueza, saneamiento, calidad del agua y tamaño del hogar). El estatus socioeconómico y la residencia urbana/rural están sólidamente integrados, pero los determinantes ambientales y comunitarios (p. ej., saneamiento comunitario, infraestructura, datos climáticos regionales) siguen estando subrepresentados. Los avances en aprendizaje automático, como Random Forest, XGBoost y los métodos de conjunto con selección de características integrada (p. ej., Boruta, LASSO, SHAP), han demostrado ser prometedores para predecir con precisión el retraso en el crecimiento; sin embargo, persisten las dificultades para incorporar las complejas características del diseño de las encuestas EDS, lo que indica la necesidad de metodologías más rigurosas, que tengan en cuenta los sesgos y que estén informadas espacialmente. 1 2 3 4 5 6 7 8 9 .

Alcance del estudio

- **Periodo de tiempo:** 2015–2024 (énfasis en los avances recientes y los estudios de validación)
- **Disciplinas:** Salud pública, nutrición, epidemiología, ciencia de datos, aprendizaje automático
- **Métodos:** Revisión sistemática, metaanálisis, validación comparativa, evaluación de modelos de aprendizaje automático, análisis de datos de encuestas

Supuestos y limitaciones

- **Supuestos:** La puntuación Z de la OMS es el estándar de referencia para el retraso en el crecimiento; los datos de DHS son representativos y comparables entre países; los modelos de aprendizaje automático se evalúan utilizando métricas estándar (precisión, AUC, puntuación F1).

- **Limitaciones:** Error de medición en la puntuación Z de la edad (especialmente en menores de 24 meses), subrepresentación de variables ambientales/comunitarias, integración limitada de diseños de encuestas complejos en modelos de aprendizaje automático y heterogeneidad en la inclusión de predictores entre estudios. [8](#) [9](#) [10](#) [11](#).

Investigación adicional sugerida

- Ampliar la inclusión de predictores ambientales y comunitarios en los modelos de aprendizaje automático.
- Desarrollar y validar herramientas predictivas móviles/desplegables en campo que integren datos en tiempo real.
- Métodos avanzados para integrar diseños de encuestas complejas (ponderaciones, estratos, UPM) en marcos de aprendizaje automático.
- Realizar estudios longitudinales sobre el impacto de la suplementación materna con micronutrientes y los factores psicosociales en las trayectorias de la puntuación Z de la edad gestacional (HAZ) de los niños.
- Estandarizar los enfoques para armonizar las referencias de crecimiento de la OMS y las regionales en los análisis multinacionales.

1. Introducción

Antecedentes y justificación

La desnutrición crónica infantil, operacionalizada como retraso en el crecimiento, sigue siendo un desafío crítico para la salud mundial, que afecta a más de 140 millones de niños menores de cinco años en todo el mundo. El retraso en el crecimiento se asocia con mayor morbilidad, deterioro del desarrollo cognitivo y menor productividad económica en la edad adulta. La medición precisa y la predicción fiable del retraso en el crecimiento son esenciales para el diseño eficaz de intervenciones y políticas. [1](#) [4](#).

La puntuación Z de talla para la edad (HAZ) de la OMS es el método de referencia para evaluar el retraso en el crecimiento, lo que permite realizar comparaciones entre países y un seguimiento global. Las Encuestas Demográficas y de Salud (EDS) proporcionan datos estandarizados a gran escala sobre el crecimiento infantil y sus determinantes, lo que las convierte en una herramienta invaluable tanto para la epidemiología descriptiva como para la modelización predictiva. Los recientes avances en aprendizaje automático (AA) ofrecen nuevas oportunidades para aprovechar los datos de las EDS en la identificación temprana de niños en riesgo y para fundamentar intervenciones específicas. [1](#) [4](#).

2. Marcos teóricos

2.1 Metodologías de medición para la desnutrición crónica infantil

Puntuación Z de talla para la edad (HAZ) de la OMS: Cálculo y estándares

- **Definición:** El HAZ se calcula como el número de desviaciones estándar que la altura de un niño se encuentra de la mediana de la población de referencia de la OMS para la misma edad y sexo.
- **Puntos de corte para el retraso en el crecimiento:** $HAZ < -2$ (retraso en el crecimiento), $HAZ < -3$ (retraso en el crecimiento grave) [12](#) [13](#) [14](#).

- **Aplicación:** Se utiliza a nivel mundial para el monitoreo, pero las estimaciones de prevalencia pueden diferir al usar referencias nacionales/regionales en lugar de los estándares de la OMS, lo que a menudo resulta en tasas de retraso en el crecimiento más altas con los estándares de la OMS. [12](#) [15](#) [16](#).

Validación y fiabilidad de las herramientas de medición de la ZAT

- **Herramientas de campo:** El gráfico mural MEIRU, la vara de medición y los dispositivos digitales han sido validados para la evaluación rápida y precisa de la ZAC en entornos con recursos limitados, con alta sensibilidad y especificidad. [10](#) [17](#) [18](#).
- **Fiabilidad:** Las mediciones antropométricas suelen ser fiables, pero los índices derivados (p. ej., HAZ) lo son menos en niños menores de 24 meses debido a errores en la declaración de la edad y en las mediciones. [19](#).

Métodos de campo rápidos y simplificados para la evaluación de la zona de peligro (ZAP).

- **Innovaciones:** RNDA, 3-MinNS y herramientas digitales basadas en sensores permiten una detección rápida y fiable del retraso en el crecimiento, facilitando la detección e intervención tempranas en entornos con recursos limitados. [20](#) [21](#) [22](#) [23](#).

Desafíos de medición relacionados con la edad y calidad de los datos

- **Desafíos:** La información errónea sobre la edad, especialmente en niños menores de 24 meses, introduce sesgos en las estimaciones de la puntuación Z de talla para la edad y la prevalencia del retraso en el crecimiento. La calidad de los datos varía entre las encuestas, lo que exige un control de calidad riguroso y, cuando sea posible, el uso de métricas alternativas como la diferencia de talla para la edad (DTA). [10](#) [11](#) [24](#).

Síntesis: La medición del retraso en el crecimiento mediante la puntuación Z de talla para la edad es sólida, pero no está exenta de dificultades. Es fundamental contar con herramientas validadas en campo y prestar especial atención al registro de la edad para obtener datos fiables, sobre todo en niños pequeños y en entornos con recursos limitados. [10](#) [18](#).

2.2 Principales predictores y determinantes del retraso en el crecimiento infantil según los datos de la DHS

Factores predictivos maternos: antropometría, educación y salud mental

- **Antropometría:** La estatura materna y el IMC son predictores fuertes y consistentes del peso al nacer (HAZ); las madres de menor estatura y con desnutrición tienen hijos con mayor riesgo de retraso en el crecimiento. [1](#) [25](#).
- **Educación:** Un mayor nivel educativo y alfabetización materna se asocia con una mejor puntuación Z de talla para la edad en los niños, independientemente del nivel socioeconómico. [1](#) [26](#).
- **Estado de micronutrientes:** El estado materno de vitamina A y hierro muestra asociaciones positivas con la puntuación Z de talla para la edad del niño, pero se utiliza poco en la mayoría de los modelos de aprendizaje automático. [25](#).

- **Salud mental:** La depresión materna y la mala salud mental aumentan significativamente el riesgo de retraso en el crecimiento, mientras que una buena salud mental materna modera los factores de riesgo intergeneracionales. [26](#) [27](#).

Factores predictivos a nivel infantil: edad, resultados del parto y prácticas de alimentación.

- **Edad:** La puntuación Z de la talla para la edad disminuye drásticamente en los primeros 24 meses, lo que convierte a la edad en un predictor fundamental. [1](#) [2](#).
- **Peso al nacer/Intervalo entre nacimientos:** El bajo peso al nacer y los intervalos cortos entre nacimientos aumentan el riesgo de retraso en el crecimiento. [1](#) [28](#).
- **Episodios de enfermedad:** Las enfermedades frecuentes (p. ej., diarrea, IRA) se asocian con un menor índice HAZ. [1](#) [29](#).
- **Prácticas de alimentación:** La lactancia materna exclusiva y el inicio temprano de la alimentación, así como las dietas ricas en proteínas, son factores protectores pero a menudo están subrepresentados en los modelos. [1](#) [29](#).

Determinantes domésticos y ambientales

- **Riqueza:** Una mayor riqueza familiar protege sistemáticamente contra el retraso en el crecimiento [30](#).
- **Saneamiento/Agua:** El acceso a un saneamiento mejorado y a agua potable, tanto a nivel doméstico como comunitario, mejora la zona de riesgo de accidentes (ZRA). [31](#) [32](#) [33](#).
- **Combustible para cocinar/Contaminación del aire interior:** El uso de combustibles sólidos y la exposición a la contaminación del aire interior se asocian con una menor zona de riesgo de hipoxia (HAZ) y un mayor riesgo de retraso en el crecimiento. [30](#) [34](#).
- **Tamaño del hogar:** Los hogares más grandes están relacionados con un mayor riesgo de retraso en el crecimiento. [1](#) [30](#).

Factores contextuales y a nivel comunitario

- **Residencia urbana/rural:** La residencia urbana y una mejor infraestructura (carreteras, electricidad) se asocian con una mayor zona de peligro (ZP). [3](#) [35](#).
- **Altitud:** La residencia a gran altitud puede afectar los patrones de crecimiento y la interpretación de la ZAC. [36](#).
- **Saneamiento comunitario:** Una mayor cobertura de saneamiento comunitario reduce el riesgo de retraso en el crecimiento, especialmente en zonas densamente pobladas. [32](#) [33](#).

Síntesis: Los determinantes maternos, infantiles y del hogar están bien establecidos, pero los predictores ambientales, psicosociales y comunitarios están subrepresentados en la mayoría de los modelos predictivos, lo que limita su exhaustividad y precisión. [1](#) [8](#) [30](#).

3. Métodos y transparencia de datos

3.1 Fuentes de datos y medición

- **Datos del DHS:** Representativos a nivel nacional, estandarizados y ampliamente utilizados para la investigación del retraso en el crecimiento y el modelado de aprendizaje automático.
- **Cálculo de HAZ:** Basado en los Patrones de Crecimiento Infantil de la OMS; el retraso en el crecimiento se define como $HAZ < -2$.
- **Herramientas de campo:** Tabla mural MEIRU, Tallstick, RNDA y dispositivos digitales validados para la evaluación rápida en entornos con recursos limitados. [18](#) [20](#).

3.2 Desarrollo de modelos de aprendizaje automático

- **Algoritmos:** Random Forest, XGBoost, SVM, redes neuronales, métodos de conjunto.
- **Selección de características:** Se utilizan métodos como Boruta, LASSO, SHAP y basados en filtros para identificar predictores clave y mejorar la interpretabilidad. [37](#) [38](#).
- **Validación del modelo:** La validación cruzada, la división de conjuntos de entrenamiento y prueba, y las técnicas de calibración (p. ej., SMOTE para el desequilibrio de clases) son estándar. [39](#) [40](#).
- **Integración del diseño de la encuesta:** Uso limitado de ponderaciones, estratos y unidades primarias de muestreo; se recomiendan modelos multinivel y métodos espaciales, pero su uso es limitado. [9](#).

3.3 Calidad y limitaciones de los datos

- **Error de medición:** Los errores en la información sobre la edad y las mediciones antropométricas, especialmente en niños menores de 24 meses, pueden sesgar las estimaciones de la puntuación Z de la edad y del retraso en el crecimiento. [10](#) [11](#).
- **Heterogeneidad de los predictores:** Variación en la inclusión de predictores entre los estudios; a menudo faltan variables ambientales y comunitarias. [8](#) [41](#).

Síntesis: Si bien los datos de DHS y la clasificación HAZ de la OMS proporcionan una base sólida, el rigor metodológico en la medición, la selección de características y la integración del diseño de la encuesta es esencial para obtener modelos de aprendizaje automático válidos y generalizables. [9](#).

4. Análisis crítico de los hallazgos

4.1 Fiabilidad y estandarización de las mediciones

- **Fortalezas:** El índice HAZ de la OMS es aceptado globalmente; las herramientas de campo rápidas están validadas para su uso en entornos con recursos limitados; los modelos multinivel y bayesianos mejoran la precisión en diversos contextos. [12](#) [18](#).
- **Limitaciones:** Los errores en la declaración de la edad y las mediciones erróneas, especialmente en niños menores de 24 meses, siguen siendo fuentes importantes de sesgo; los estándares de la OMS pueden sobreestimar el retraso en el crecimiento en algunas regiones. [10](#) [12](#).

4.2 Heterogeneidad de los predictores y rendimiento del modelo

- **Factores maternos predictivos:** La estatura, la educación y el estado nutricional son sólidos; la salud mental y el estado de micronutrientes son importantes pero están infrautilizados. [1](#) [26](#).
- **Factores predictivos en la infancia:** La edad, el peso al nacer y los episodios de enfermedad son consistentemente factores importantes; las prácticas de alimentación y los factores psicosociales se incluyen con menor frecuencia. [1](#) [29](#).
- **Factores predictivos del hogar y el medio ambiente:** La riqueza, el saneamiento y la contaminación del aire en interiores son clave; las variables ambientales y comunitarias están subrepresentadas, lo que limita la precisión del modelo y su relevancia para las políticas. [8](#) [30](#).
- **Predictores comunitarios:** La residencia urbana/rural y la infraestructura son importantes, pero rara vez se integran en los modelos de aprendizaje automático. [3](#) [35](#).

4.3 Eficacia del modelo de aprendizaje automático

- **Rendimiento del algoritmo:** Random Forest, XGBoost y los métodos de conjunto superan sistemáticamente a los modelos tradicionales en la predicción del retraso del crecimiento, con una precisión de hasta el 96 % en algunos entornos. [5](#) [6](#) [7](#).
- **Selección de características:** Boruta, LASSO y SHAP mejoran tanto la precisión como la interpretabilidad, lo que permite identificar predictores clave para su uso clínico y en políticas públicas. [37](#) [38](#).
- **Generalización:** Los métodos de conjunto y las técnicas de calibración (por ejemplo, SMOTE) mejoran el rendimiento del modelo en diversos conjuntos de datos DHS. [39](#) [40](#).
- **Integración del diseño de encuestas:** La mayoría de los modelos incorporan de forma inadecuada las características complejas del diseño de encuestas, lo que conlleva el riesgo de sesgo y limita la generalización. [9](#).

4.4 Brechas y limitaciones

- **Predictores subrepresentados:** Las variables ambientales, psicosociales y comunitarias rara vez se incluyen, a pesar de la evidencia de su importancia. [8](#) [41](#).
- **Diseño de la encuesta:** Uso limitado de ponderaciones, estratos y unidades primarias de muestreo en los modelos de aprendizaje automático; se recomiendan los métodos multinivel y espaciales, pero no se adoptan ampliamente. [9](#).
- **Impacto longitudinal:** La evidencia sobre los efectos sostenidos de la suplementación materna con micronutrientes en la talla para la edad del niño es limitada e inconsistente. [42](#) [43](#).

Síntesis: Si bien los modelos de aprendizaje automático que utilizan datos de DHS y la puntuación Z de la OMS para la edad han mejorado la predicción del retraso en el crecimiento, las deficiencias metodológicas — especialmente en la inclusión de predictores y la integración del diseño de la encuesta — limitan su pleno potencial para fundamentar las intervenciones. [8](#) [9](#).

5. Implicaciones en el mundo real

5.1 Diseño de políticas y programas

- **Intervenciones focalizadas:** La identificación de niños y hogares de alto riesgo permite una asignación más eficiente de recursos e intervenciones adaptadas a las necesidades específicas (por ejemplo, educación materna, mejoras en el saneamiento, combustibles limpios para cocinar). [1](#) [34](#).
- **Acción a nivel comunitario:** La incorporación de variables de saneamiento e infraestructura comunitarias puede fundamentar estrategias de salud pública más amplias y adaptadas al contexto. [32](#) [33](#).
- **Herramientas móviles y de campo:** Las herramientas de campo rápidas y validadas, así como las aplicaciones móviles, pueden facilitar la detección e intervención tempranas, especialmente en entornos con recursos limitados. [22](#) [44](#).

5.2 Avances en el análisis predictivo

- **Implementación de modelos de aprendizaje automático:** Los modelos de aprendizaje automático híbridos y de conjunto con una sólida selección de características pueden integrarse en los sistemas de información sanitaria para la evaluación de riesgos en tiempo real. [5](#) [6](#) [7](#).
- **Integración de datos:** La vinculación de los datos del DHS con conjuntos de datos ambientales y geoespaciales puede mejorar la precisión de los modelos y respaldar una salud pública de precisión. [45](#).
- **Mitigación de sesgos:** La incorporación de características de diseño de encuestas complejas y modelado espacial reduce el sesgo y mejora la validez de las predicciones para la planificación de políticas y programas. [9](#).

Síntesis: La integración de herramientas de medición validadas, conjuntos de predictores completos y modelos de aprendizaje automático avanzados tiene el potencial de transformar la vigilancia e intervención del retraso en el crecimiento, pero requiere rigor metodológico y adaptación al contexto específico. [1](#) [5](#) [44](#).

6. Futuras direcciones de investigación

6.1 Determinantes ambientales y sociales subrepresentados

- **Ampliar los conjuntos de predictores:** Integrar las exposiciones ambientales (p. ej., clima, contaminación atmosférica), el saneamiento a nivel comunitario y los factores psicosociales en los modelos de aprendizaje automático para mejorar la precisión y la relevancia. [8](#) [41](#).
- **Factores conductuales y de salud:** Incluir la salud mental materna, las prácticas de alimentación y la utilización de servicios de salud como predictores estándar. [26](#) [27](#).

6.2 Técnicas avanzadas de aprendizaje automático

- **Modelos híbridos y de aprendizaje profundo:** Emplean métodos de aprendizaje profundo, de conjunto y de IA explicable para capturar no linealidades e interacciones complejas entre predictores. [46](#) [47](#) [48](#).

- **Modelado espacial:** Integrar datos geospaciales y a nivel comunitario para la predicción de riesgos localizados y la focalización de intervenciones. [45](#) [49](#).

6.3 Algoritmos predictivos móviles y desplegados en campo

- **Aplicaciones móviles de salud:** Desarrollar y validar herramientas móviles que aprovechen los modelos de aprendizaje automático para la evaluación e intervención de riesgos en tiempo real y sobre el terreno. [22](#) [44](#).
- **Integración de IoT:** Explore el uso de sensores antropométricos basados en IoT para la recopilación automatizada y precisa de datos en entornos con recursos limitados.

6.4 Integración óptima del diseño de encuestas complejas

- **Características del diseño de la encuesta:** Estandarizar el uso de ponderaciones, estratos y unidades primarias de muestreo (UPM) en los modelos de aprendizaje automático; emplear métodos multinivel y bayesianos para tener en cuenta las dependencias de datos y la agrupación. [9](#).
- **Estimación de la varianza:** Utilice técnicas de estimación de la varianza apropiadas (por ejemplo, bootstrap, linealización de Taylor) para garantizar una inferencia no sesgada. [9](#).

6.5 Investigación longitudinal e intervencional

- **Suplementación materna:** Realizar estudios longitudinales sobre el impacto de la suplementación materna con micronutrientes y las intervenciones psicosociales en las trayectorias del HAZ infantil. [42](#) [43](#).
- **Estandarización:** Armonizar el uso de las referencias de crecimiento de la OMS y las regionales en los análisis multinacionales para mejorar la comparabilidad y la relevancia de las políticas. [12](#) [15](#).

Síntesis: Las investigaciones futuras deberían priorizar la inclusión de predictores integrales y sensibles al contexto, el rigor metodológico en la integración del diseño de encuestas y el desarrollo de herramientas predictivas escalables y listas para su uso en campo para avanzar en la medición y prevención del retraso en el crecimiento infantil. [8](#) [9](#) [44](#).

7. Conclusión

Resumen de perspectivas y recomendaciones

- **Medición:** La puntuación Z de la OMS sigue siendo el método de referencia para la evaluación del retraso en el crecimiento, pero la fiabilidad de las mediciones, especialmente en niños pequeños, requiere atención constante. Las herramientas de campo rápidas y las innovaciones digitales son prometedoras para entornos con recursos limitados. [12](#) [18](#).
- **Determinantes:** Los factores predictivos maternos, infantiles y del hogar están bien establecidos, pero los determinantes ambientales, psicosociales y comunitarios están subrepresentados en la mayoría de los modelos, lo que limita su exhaustividad. [1](#) [8](#) [30](#).
- **Aprendizaje automático:** Los modelos de aprendizaje automático híbridos y de conjunto con selección de características robusta (Boruta, LASSO, SHAP) superan a los enfoques tradicionales, pero se necesita la

integración de diseños de encuestas complejos y variables contextuales para obtener predicciones imparciales y generalizables. [5](#) [6](#) [7](#) [9](#).

- **Política y práctica:** La estratificación de riesgos basada en aprendizaje automático y las herramientas móviles/desplegables en campo pueden mejorar la detección temprana y la intervención dirigida, pero requieren una adaptación específica al contexto y una validación rigurosa. [44](#).
- **Brechas en la investigación:** Los estudios futuros deberían ampliar los conjuntos de predictores, estandarizar la integración del diseño de encuestas y desarrollar algoritmos predictivos escalables y listos para su uso en campo para fundamentar estrategias eficaces de prevención e intervención del retraso en el crecimiento. [8](#) [9](#) [44](#).

En resumen, la combinación de mediciones sólidas, la inclusión integral de predictores y el aprendizaje automático avanzado con una integración rigurosa del diseño de encuestas es esencial para avanzar en la ciencia y la práctica de la prevención y el control del retraso en el crecimiento infantil.

Referencias

1. Application of ordinal logistic regression analysis in determining risk factors of child malnutrition in Bangladesh Das, S., Rahman, R.M. Nutrition Journal, 2011
<https://www.scopus.com/pages/publications/85027930254?origin=scopusAI>
2. On exploring and ranking risk factors of child malnutrition in Bangladesh using multiple classification analysis Bhowmik, K.R., Das, S. BMC Nutrition, 2017
<https://www.scopus.com/pages/publications/85059193181?origin=scopusAI>
3. Socioeconomic determinants of child health: Empirical evidence from Indonesia Mani, S. Asian Economic Journal, 2014 <https://www.scopus.com/pages/publications/84896819562?origin=scopusAI>
4. Determinants of height-for-age Z-score (HAZ) among Ethiopian children aged 0–59 months: a multilevel mixed-effects analysis Amaha, N.D. BMC Public Health, 2025
<https://www.scopus.com/pages/publications/105003967310?origin=scopusAI>
5. Exploring Risk Factors and Predictive Modeling of Child Malnutrition in Pakistan Using Machine Learning Saleem, M.U., Aslam, M.U., Khatir, A.G., Jiang, Q. American Journal of Human Biology, 2025
<https://www.scopus.com/pages/publications/105014970789?origin=scopusAI>
6. Efficient Machine Learning for Malnutrition Prediction among under-five children in India Jain, S., Khanam, T., Abedi, A.J., Khan, A.A. 2022 IEEE Delhi Section Conference, DELCON 2022, 2022
<https://www.scopus.com/pages/publications/85129418462?origin=scopusAI>
7. Predictive Power of AI: Tackling Child Undernutrition in Morocco Berrouyne, M., Hami, H., Jouilil, Y. 2024 International Conference on Intelligent Systems and Computer Vision, ISCV 2024, 2024
<https://www.scopus.com/pages/publications/85202351684?origin=scopusAI>
8. Machine learning algorithms for predicting undernutrition among under-five children in Ethiopia Bitew, F.H., Sparks, C.S., Nyarko, S.H. Public Health Nutrition, 2022
<https://www.scopus.com/pages/publications/85117102429?origin=scopusAI>
9. Evaluating the current methodological practices and issues in existing literature in pooling complex surveys: a systematic review Mayen, M.S.A., Nisha, S.N., Afrin, S., (...), Uddin, M.J. BMC Medical Research Methodology, 2024 <https://www.scopus.com/pages/publications/85209171167?origin=scopusAI>

10. Establishing Height-for-Age Z-Score Growth Reference Curves and Stunting Prevalence in Children and Adolescents in Pakistan Asif, M., Aslam, M., Mazhar, I., (...), Wyszyńska, J. *International Journal of Environmental Research and Public Health*, 2022 <https://www.scopus.com/pages/publications/85139812467?origin=scopusAI>
11. Correcting for artifactual correlation between misreported month of birth and attained height-for-age reduces but does not eliminate measured vulnerability to season of birth in poorer countries Finaret, A.B., Masters, W.A. *American Journal of Clinical Nutrition*, 2019 <https://www.scopus.com/pages/publications/85070849755?origin=scopusAI>
12. Differences in the prevalence of malnutrition resulting from using a national growth reference or an international growth reference Oyhenart, E.E., Orden, A.B. *Revista Panamericana de Salud Publica/Pan American Journal of Public Health*, 2005 <https://www.scopus.com/pages/publications/27144490307?origin=scopusAI>
13. Implications of the WHO Child Growth Standards in rural Honduras Nichols, E.K., Nichols, J.S., Selwyn, B.J., (...), Day, R.S. *Public Health Nutrition*, 2012 <https://www.scopus.com/pages/publications/84864127591?origin=scopusAI>
14. The implications of using the world health organization child growth standards in Saudi Arabia El Mouzan, M.I., Foster, P.J., Al Herbish, A.S., (...), Kecojevic, T. *Nutrition Today*, 2009 <https://www.scopus.com/pages/publications/67650948509?origin=scopusAI>
15. Comparison of Indonesian Growth Reference Chart and World Health Organization Child Growth Standard in Detecting Stunting: A Systematic Review and Meta-analysis of 15,874 Children Octavius, G.S., Pardede, C.S.B., Thandy, C.C., (...), Juliansen, A. *JCRPE Journal of Clinical Research in Pediatric Endocrinology*, 2022 <https://www.scopus.com/pages/publications/85125682650?origin=scopusAI>
16. Variations in estimates of underweight, stunting, wasting, overweight and obesity in children from Argentina comparing three growth charts Padula, G., Seoane, A.I., Salceda, S.A. *Public Health Nutrition*, 2012 <https://www.scopus.com/pages/publications/84867729461?origin=scopusAI>
17. Field validation of the tallstick in marginal communities in Nicaragua Seireg, M., Zeitlin, M.F., Jessica, L., Morales G, C.M. *Journal of Tropical Pediatrics*, 1992 <https://www.scopus.com/pages/publications/0026754611?origin=scopusAI>
18. Tools for assessing child and adolescent stunting: Lookup tables, growth charts and a novel appropriate-technology "MEIRU" wallchart - a diagnostic accuracy study Chanyarungrojn, P.A., Lelijveld, N., Crampin, A., (...), Kerac, M. *PLOS Global Public Health*, 2023 <https://www.scopus.com/pages/publications/85195606247?origin=scopusAI>
19. Anthropometric data quality assessment in multisurvey studies of child growth Perumal, N., Namaste, S., Qamar, H., (...), Roth, D.E. *American Journal of Clinical Nutrition*, 2020 <https://www.scopus.com/pages/publications/85091126396?origin=scopusAI>
20. Validation and adaptation of rapid neurodevelopmental assessment instrument for infants in Guatemala Thompson, L., Peñaloza, R.A., Stormfields, K., (...), Khan, N.Z. *Child: Care, Health and Development*, 2015 <https://www.scopus.com/pages/publications/84959333245?origin=scopusAI>
21. The risk of under-nutrition in hospitalised Malaysian children: Use of 3-minute nutrition screening-paediatrics (Paediatric 3-MinNS) Yeo, P.S., Majid, H.A. *Journal of the Pakistan Medical Association*, 2024 <https://www.scopus.com/pages/publications/85195831842?origin=scopusAI>
22. EARLY DETECTION OF STUNTING AND USER SATISFACTION: AN OVERVIEW OF ANTHROPOMETRIC MEASUREMENT IN INDONESIAN TODDLERS Elisanti, A.D., Ardianto, E.T., Dewanto, W.K., (...), Yanti *Southeast Asian Journal of Tropical Medicine and Public Health*, 2022 <https://www.scopus.com/pages/publications/85163295762?origin=scopusAI>

23. **STRONGkids** nutrition screening tool in pediatrics: An analysis of cutoff points in Brazil Castro, J.D.S., Santos, C.A.D., Rosa, C.D.O.B., (...), Ribeiro, A.Q. *Nutrition in Clinical Practice*, 2022
<https://www.scopus.com/pages/publications/85120965945?origin=scopusAI>
24. Linear growth deficit continues to accumulate beyond the first 1000 days in low- and middle-income Countries: Global evidence from 51 national surveys Leroy, J.L., Ruel, M., Habicht, J.-P., Frongillo, E.A. *Journal of Nutrition*, 2014 <https://www.scopus.com/pages/publications/84906910677?origin=scopusAI>
25. Effects of Iron and Vitamin A Levels on Pregnant Women and Birth Outcomes: Complex Relationships Untangled Using a Birth Cohort Study in Uganda Mezzano, J., Namirembe, G., Ausman, L.M., (...), Ghosh, S. *Maternal and Child Health Journal*, 2022 <https://www.scopus.com/pages/publications/85125591389?origin=scopusAI>
26. Mitigating the Impact of Intergenerational Risk Factors on Stunting: Insights From Seven of the Most Food Insecure Districts in South Africa Rich, K., Engelbrecht, L., Wills, G., Mphaphuli, E. *Maternal and Child Nutrition*, 2025 <https://www.scopus.com/pages/publications/85210031081?origin=scopusAI>
27. Association between maternal depression and child stunting in Northern Ghana: A cross-sectional study Wemakor, A., Mensah, K.A. *BMC Public Health*, 2016
<https://www.scopus.com/pages/publications/85007559668?origin=scopusAI>
28. Child feeding practices are associated with child nutritional status in Latin America: Innovative uses of the Demographic and Health Surveys Ruel, M.T., Menon, P. *Journal of Nutrition*, 2002
<https://www.scopus.com/pages/publications/0036274991?origin=scopusAI>
29. Trends and long-term variation explaining nutritional determinants of child linear growth: Analysis of Bangladesh Demographic and Health Surveys 1996-2018 Ahmed, K.T., Karimuzzaman, M., Afroz, S., (...), Rahman, A. *Public Health Nutrition*, 2023 <https://www.scopus.com/pages/publications/85176090530?origin=scopusAI>
30. Association of solid fuel use with risk of stunting in children living in China Liang, W., Wang, B., Shen, G., (...), Duan, X. *Indoor Air*, 2020 <https://www.scopus.com/pages/publications/85076101984?origin=scopusAI>
31. Effects of indoor air pollution due to solid fuel combustion on physical growth of children under 5 in Sri Lanka: A descriptive cross sectional study Ranathunga, N., Perera, P., Nandasena, S., (...), Wickremasinghe, A.R. *PLoS ONE*, 2021 <https://www.scopus.com/pages/publications/85106561574?origin=scopusAI>
32. A study of the association between improved sanitation facilities and children's height in Lesotho Daniels, D.L., Cousens, S.N., Makoe, L.N., Feachem, R.G. *European Journal of Clinical Nutrition*, 1991
<https://www.scopus.com/pages/publications/0025760179?origin=scopusAI>
33. Influence of community-level sanitation coverage and population density on environmental fecal contamination and child health in a longitudinal cohort in rural Bangladesh Contreras, J.D., Islam, M., Mertens, A., (...), Ercumen, A. *International Journal of Hygiene and Environmental Health*, 2022
<https://www.scopus.com/pages/publications/85137717234?origin=scopusAI>
34. Indoor air pollution and child development in Indonesia: Stunted by the smoke? Kim, Y., Manley, J., Radoias, V. *Development Policy Review*, 2023 <https://www.scopus.com/pages/publications/85168681962?origin=scopusAI>
35. Sanitation and child health in India Augsburg, B., Rodríguez-Lesmes, P.A. *World Development*, 2018
<https://www.scopus.com/pages/publications/85043473708?origin=scopusAI>
36. Open defecation explains differences in nutritional status between Bengali and tribal children in the Chittagong Hill Tracts of Bangladesh Sinharoy, S.S., Waid, J.L., Freeman, M.C., Stein, A.D. *Ethnicity and Health*, 2019 <https://www.scopus.com/pages/publications/85021682516?origin=scopusAI>
37. Impact of Filter-Based Feature Selection on Prediction Model Performance for Early Detection of Stunting Widiastuti, S.H., Purwanto, Wibowo, A., Wisnuwardani, R.W. 2024 9th International Conference on

Informatics and Computing, ICIC 2024, 2024 <https://www.scopus.com/pages/publications/105004582452?origin=scopusAI>

38. Comprehensive Review of Machine Learning Applications on the DHS Dataset Across Multiple Countries Kamal, A., Shahid, N., Amir, J., Shah, S.A. STEAM-H: Science, Technology, Engineering, Agriculture, Mathematics and Health, 2025 <https://www.scopus.com/pages/publications/85216771773?origin=scopusAI>

39. Performance of Machine Learning Classifiers in Classifying Stunting among Under-Five Children in Zambia Chilyabanyama, O.N., Chilengi, R., Simuyandi, M., (...), Bosomprah, S. Children, 2022 <https://www.scopus.com/pages/publications/85135607643?origin=scopusAI>

40. Health and Socio-Demographic Risk Factors of Childhood Stunting: Assessing the Role of Factor Interactions Through the Development of an AI Predictive Model Hariguna, T., Sarmini, Azis, A. Journal of Applied Data Sciences, 2024 <https://www.scopus.com/pages/publications/85213329335?origin=scopusAI>

41. Machine Learning in Predicting Child Malnutrition: A Meta-Analysis of Demographic and Health Surveys Data Rao, B., Rashid, M., Hasan, M.G., Thunga, G. International Journal of Environmental Research and Public Health, 2025 <https://www.scopus.com/pages/publications/105001311199?origin=scopusAI>

42. No effect of maternal micronutrient supplementation on early childhood growth in rural western China: 30 month follow-up evaluation of a double blind, cluster randomized controlled trial Wang, W., Yan, H., Zeng, L., (...), Li, Q. European Journal of Clinical Nutrition, 2012 <https://www.scopus.com/pages/publications/84856668683?origin=scopusAI>

43. Maternal antenatal multiple micronutrient supplementation for long-term health benefits in children: A systematic review and meta-analysis Devakumar, D., Fall, C.H.D., Sachdev, H.S., (...), Osrin, D. BMC Medicine, 2016 <https://www.scopus.com/pages/publications/84974818412?origin=scopusAI>

44. A Mobile-Based Approach to Enhance Knowledge of Infant and Young Child Feeding Among Teenage Mothers in Nigeria: A Randomized Controlled Trial Sosanya, M.E., Adesanya, O.D., Rufai, H.E., Freeland-Graves, J.H. Nutrients , 2025 <https://www.scopus.com/pages/publications/85217785258?origin=scopusAI>

45. Integrating the demographic and health surveys, IPUMS-I, and TerraPopulus to explore mortality and health outcomes at the district level in Ghana, Malawi, and Tanzania Robinson, R.S., Meier, A., Trinitapoli, J., Svec, J. Etude de la Population Africaine, 2014 <https://www.scopus.com/pages/publications/84915754834?origin=scopusAI>

46. Advancing predictive analytics in child malnutrition: Machine, ensemble and deep learning models with balanced class distribution for early detection of stunting and wasting Mgonezulu, W.R., Thangata, P., Mkandawire, B., Amoah, N. Human Nutrition and Metabolism, 2025 <https://www.scopus.com/pages/publications/105013592012?origin=scopusAI>

47. A Dual-Fusion Hybrid Model with Attention for Stunting Prediction among Children under Five Years Hadikurniawati, W., Hartomo, K.D., Sembiring, I., Arthur, C. Journal of Applied Data Sciences, 2025 <https://www.scopus.com/pages/publications/105012360584?origin=scopusAI>

48. Enhancing nutritional status prediction through attention-based deep learning and explainable AI Santoso, H.A., Dewi, N.S., Haw, S.-C., (...), Wulandari, S.A. Intelligence-Based Medicine, 2025 <https://www.scopus.com/pages/publications/105004674057?origin=scopusAI>

49. Hybridizing spatial machine learning to explore the fine-scale heterogeneity between stunting prevalence and its associated risk determinants in Rwanda Nduwayezu, G., Mansourian, A., Bizimana, J.P., Pilesjö, P. Geo-Spatial Information Science, 2025 <https://www.scopus.com/pages/publications/86000522796?origin=scopusAI>